

Machine Learning และ Data Science

Machine Learning เป็นส่วนหนึ่งของแขนงความรู้ด้าน **Data Science** และเกี่ยวข้องกับ **Data Processing** รวมถึง **Image Processing** อย่างที่เราเคยเรียนกันไปแล้ว โดยแนวคิดสำคัญของ Machine Learning คือการทำให้คอมพิวเตอร์สามารถ **เรียนรู้รูปแบบ (Pattern) จากข้อมูล** และนำสิ่งที่เรียนรู้ไปใช้กับข้อมูลใหม่ได้ โดยเราไม่จำเป็นต้องเขียนกฎของทุกกรณีเอาไว้เองทั้งหมด

ในคาบอาจารย์ได้พูดถึง **Teachable Machine** หรือคำศัพท์ที่อาจารย์ชอบเน้นย้ำบ่อย ๆ คือ

What can I use to teach a machine?

ถ้าผมเป็น Supervisor หรือผู้ที่ทำหน้าที่สอน Machine เราสามารถนำข้อมูลหลายรูปแบบมาใช้ในการ Train Machine ได้ โดยใน Teachable Machine สามารถทดลองสอน Machine จากข้อมูลหลัก ๆ ได้ เช่น

1. ภาพ (Image)
2. เสียง (Audio)
3. ท่าทาง (Pose)

สิ่งที่เรานำมา Train นั้นจะต้องมีจำนวนข้อมูลที่เพียงพอและมีความหลากหลาย เพื่อให้ Machine สามารถเรียนรู้ลักษณะของข้อมูลได้จริง เช่น หากเราต้องการสอน Machine ให้แยกภาพระหว่าง “แมว” และ “สุนัข” เราจะต้องมีตัวอย่างภาพของทั้งแมวและสุนัขจำนวนหนึ่ง ไม่ใช่ให้ Machine ดูเพียงภาพเดียวแล้วคิดว่าภาพนั้นเป็นตัวแทนของแมวหรือสุนัขทั้งหมด

เมื่อเราเข้าไปทดลองที่เว็บไซต์ [Teachable Machine](#) จะเห็นว่าหลังจาก Train แล้ว Machine จะสามารถแสดงค่าเป็น **เปอร์เซ็นต์ความมั่นใจ (Confidence)** ของแต่ละ Class ว่าข้อมูลที่กำลังนำเข้าใกล้เคียงกับข้อมูลที่เคย Train ของ Class ใดมากที่สุด

ตัวอย่างเช่น

- Cat = 90%
- Dog = 8%
- Other = 2%

ไม่ได้หมายความว่า Machine “รู้แน่นอน 90% ว่าเป็นแมว” แต่หมายถึงโมเดลให้คะแนนความมั่นใจหรือความน่าจะเป็นตามวิธีที่โมเดลนั้นคำนวณว่า Input มีความสอดคล้องกับ Class นั้นมากกว่า Class อื่น

มอง Machine Learning ในมุมมองทางคณิตศาสตร์

เราสามารถมอง Machine Learning ในรูปแบบง่าย ๆ ทางคณิตศาสตร์ได้ว่า

x = Input / Sample

y = Output / Label หรือคำตอบที่เราต้องการ

เช่น เราต้องการให้ Machine เรียนรู้ว่า “ภาพนี้เป็นแมวหรือสุนัข”

ดังนั้น

- **x** = รูปภาพที่นำมาให้ Machine เรียนรู้
- **y** = คำตอบว่าเป็น Cat หรือ Dog

ในกรณีที่เรามีคำตอบกำกับไว้แล้ว เราเรียกว่า **Labeled Data**

Machine Learning จะพยายามเรียนรู้ความสัมพันธ์ระหว่าง

$x \rightarrow y$

หรือพูดง่าย ๆ คือ

“ถ้า Machine ได้ข้อมูล x เข้ามา แล้วควรให้ผลลัพธ์ y ออกมาเป็นอะไร”

ในทางคณิตศาสตร์ เราอาจมองเป็นการหา Function ได้ว่า

$$y = f(x)$$

แต่ใน Machine Learning เราไม่ได้กำหนด Function ให้ Machine แบบตรง ๆ เสมอไป แต่เรานำข้อมูลตัวอย่างจำนวนมากให้ Machine เรียนรู้ เพื่อให้มันสามารถประมาณ Function หรือรูปแบบความสัมพันธ์ที่เหมาะสมจากข้อมูลได้

ดังนั้นการ Train Machine จึงไม่ใช่แค่การ “จำข้อมูล” แต่เป้าหมายสำคัญคือการเรียนรู้ Pattern ที่สามารถนำไปใช้กับข้อมูลใหม่ได้

Data Science 5 ขั้นตอน

Data Science สามารถมองเป็นกระบวนการตั้งแต่การทำความเข้าใจปัญหา ไปจนถึงการนำข้อมูลหรือ Model ไปใช้งานจริง โดยสามารถสรุปแนวคิดหลัก ๆ ได้ดังนี้

1. เข้าใจปัญหาและเป้าหมาย

ก่อนที่จะเริ่มใช้ Machine Learning เราต้องรู้ก่อนว่า

เรากำลังแก้ปัญหาอะไร?

และ

ทำไมเพื่ออะไร?

ต้องกำหนดเป้าหมายและขอบเขตของปัญหาให้ชัดเจน เช่น บริษัทต้องการตรวจจับธุรกรรมที่ผิดปกติ เราต้องรู้ว่า “ผิดปกติ” หมายถึงอะไร และผลลัพธ์ที่ต้องการคือการจัดกลุ่มธุรกรรมหรือการทำนายว่าธุรกรรมนั้นมีความเสี่ยงหรือไม่

การเริ่มจากปัญหาก่อนสำคัญ เพราะไม่ใช่ทุกปัญหาที่จำเป็นต้องใช้ Machine Learning

2. รวบรวมข้อมูล

หลังจากเข้าใจปัญหาแล้วจึงเริ่มรวบรวม **Raw Data** จากแหล่งต่าง ๆ เช่น

- ภาพถ่าย
- เสียง
- วิดีโอ
- ข้อมูลจาก Sensor
- ข้อมูลจาก Database
- ข้อมูลจาก Website หรือ API
- ข้อมูลจากระบบขององค์กร

นอกจากนี้ต้องคำนึงถึงเรื่อง **สิทธิ์ในการใช้ข้อมูล (Data Ownership)**, Privacy และกฎหมายที่เกี่ยวข้องด้วย เพราะการมีข้อมูลไม่ได้หมายความว่าเราสามารถนำข้อมูลนั้นมาใช้ได้โดยไม่มีข้อจำกัด

3. เตรียมข้อมูล (Data Preparation)

Raw Data ที่ได้มาส่วนใหญ่มักยังไม่พร้อมนำไปใช้กับ Model เราจึงต้องจัดการข้อมูลก่อน เช่น

Clean

ตรวจสอบข้อมูลที่ผิดพลาด ข้อมูลซ้ำ ข้อมูลที่หายไป หรือข้อมูลที่ไม่สมเหตุสมผล

Transformation

เปลี่ยนรูปแบบข้อมูลให้อยู่ในรูปแบบที่เหมาะสม เช่น การ Normalize หรือแปลงข้อมูลให้อยู่ในรูปแบบที่ Model สามารถประมวลผลได้

Combining

รวมข้อมูลจากหลายแหล่งเข้าด้วยกัน

Labeling

ในกรณีของ Supervised Learning ต้องมีการกำหนด Label ให้ข้อมูล เช่น

- ภาพนี้ = Cat
- ภาพนี้ = Dog

ขั้นตอนนี้มีความสำคัญมาก เพราะถ้าข้อมูลที่นำไป Train มีปัญหา ต่อให้ใช้ Model ที่ดีมากก็อาจได้ผลลัพธ์ที่ไม่ดี

4. วิเคราะห์ข้อมูลและสร้าง Model

เมื่อข้อมูลพร้อมแล้ว เราสามารถวิเคราะห์ข้อมูลในเชิงสถิติ เช่น ค่าเฉลี่ย การกระจายตัว ความสัมพันธ์ระหว่างตัวแปร หรือ Pattern ที่เกิดขึ้นในข้อมูล

จากนั้นจึงเลือก Algorithm ที่เหมาะสมกับปัญหา เช่น

- Classification
- Regression
- Clustering

และนำข้อมูลเข้าสู่กระบวนการ **Training**

ในขั้นตอนนี้ Machine จะพยายามเรียนรู้ความสัมพันธ์หรือ Pattern จากข้อมูลที่เราให้

5. นำผลลัพธ์ไปใช้งานจริง

หลังจากได้ Model แล้ว เราต้องประเมินก่อนว่า Model ทำงานได้ดีเพียงใด หากผ่านเกณฑ์ที่กำหนดจึงนำไป **Deploy** หรือใช้งานจริง

ตัวอย่างเช่น

เราสร้าง Model ตรวจสอบธุรกรรมผิดปกติ → Train → Evaluate → ผ่านเกณฑ์ → นำ Model ไปอยู่ในระบบธนาคาร → เมื่อมีธุรกรรมใหม่เข้ามา Model จะช่วยประเมินว่าธุรกรรมนั้นมีลักษณะผิดปกติหรือไม่

ดังนั้น Data Science จึงไม่ได้จบแค่การ Train Model แต่ต้องมองตั้งแต่ **Problem** → **Data** →

Preparation → **Analysis** → **Model** → **Deployment**

Industry Use

Machine Learning สามารถนำไปใช้ในอุตสาหกรรมได้หลายรูปแบบ ตัวอย่างเช่น

1. Medical / Healthcare

ใช้ในการช่วยวิเคราะห์ภาพทางการแพทย์ เช่น X-ray หรือ CT Scan เพื่อช่วยตรวจหาลักษณะที่อาจสัมพันธ์กับโรค

ตัวอย่างเช่น การนำภาพ X-ray ปอดที่มี Label ว่าเป็นโรคหรือไม่เป็นโรคมารวม Train Model เพื่อให้ Model เรียนรู้ Pattern ของภาพ

อย่างไรก็ตาม ในระบบจริง Model ไม่ควรถูกมองว่าเป็นผู้ตัดสินใจแทนแพทย์โดยอัตโนมัติ แต่สามารถใช้เป็น **Decision Support** เพื่อช่วยแพทย์วิเคราะห์ข้อมูลได้

2. Quality Inspection

ใช้ตรวจสอบตำหนิของสินค้าในโรงงาน เช่น

- สินค้ามีรอยแตกหรือไม่
- ชิ้นส่วนประกอบถูกต้องหรือไม่
- สินค้ามีตำหนิหรือไม่

โดยอาจใช้กล้องถ่ายภาพสินค้า แล้วใช้ Image Processing ร่วมกับ Machine Learning เพื่อ Classification ว่าสินค้านั้นเป็น **Pass หรือ Defect**

3. Object Classification

ใช้แยกประเภทของสิ่งของ เช่น

- พลาสติก
- โลหะ
- กระดาษ
- แก้ว

ซึ่งสามารถนำไปใช้กับระบบคัดแยกขยะอัตโนมัติได้

4. Finance / Fraud Detection

ใช้ Machine Learning ในการตรวจจับพฤติกรรมทางการเงินที่ผิดปกติ เช่น

ผู้ใช้คนหนึ่งทำธุรกรรมอยู่ในประเทศ A แล้วในเวลาใกล้เคียงกันกลับมีธุรกรรมเกิดขึ้นในประเทศ B ซึ่งอาจเป็น Pattern ที่ผิดปกติ

Model สามารถเรียนรู้จากธุรกรรมในอดีตและช่วยให้คะแนนความเสี่ยงของธุรกรรมใหม่ได้

5. Marketing Recommendation

ระบบ Recommendation เช่น Netflix, YouTube หรือระบบ E-commerce สามารถนำข้อมูลพฤติกรรมของผู้ใช้มาใช้ในการแนะนำ Content หรือสินค้า

ตัวอย่างเช่น

User A ชอบดู Content กลุ่มหนึ่ง

→ ระบบเรียนรู้พฤติกรรม

→ พบว่าผู้ใช้ที่มีพฤติกรรมคล้ายกันมักชอบ Content อีกกลุ่ม

→ ระบบจึงนำ Content นั้นมา Recommend ให้ User A

แนวคิดนี้เกี่ยวข้องกับการค้นหา **ความสัมพันธ์และความคล้ายกันของข้อมูล**

Machine Learning Type

Machine Learning สามารถแบ่งตามลักษณะการเรียนรู้ได้หลายประเภท โดยพื้นฐานที่สำคัญคือ **Supervised Learning และ Unsupervised Learning**

1. Supervised Learning

Supervised Learning คือการ Train Machine ด้วยข้อมูลที่มี **Label หรือคำตอบกำกับไว้แล้ว** พยายาม ๆ คือ

เราให้ข้อสอบ + เฉลย กับ Machine แล้วให้ Machine เรียนรู้จากข้อสอบและเฉลยเหล่านั้น
ในรูปแบบง่าย ๆ คือ

$x \rightarrow y$

โดย x คือ Input และ y คือ Target / Label

Supervised Learning ที่สำคัญมี 2 รูปแบบ

1.1 Classification

Classification คือการทำนายว่า Input ควรอยู่ใน **กลุ่มหรือ Class** ใด

ตัวอย่างเช่น

- Cat / Dog
- Spam / Not Spam
- Pass / Fail
- Disease / No Disease

ผลลัพธ์จึงเป็น Class ที่กำหนดไว้

เช่น

x = รูปภาพ

y = Cat

เมื่อมีภาพใหม่เข้ามา Model จะนำ Pattern ที่เรียนรู้มาใช้จำแนกว่าอยู่ใน Class ใด

1.2 Regression

Regression คือการทำนาย **ค่าตัวเลขต่อเนื่อง**

ตัวอย่างเช่น

- ทำนายราคาบ้าน
- ทำนายอุณหภูมิ
- ทำนายยอดขาย
- ทำนายปริมาณการใช้ไฟฟ้า

ตัวอย่าง

x = ขนาดบ้าน + จำนวนห้อง + ทำเล

y = ราคาบ้าน

ในกรณีนี้ y ไม่ใช่ Class แต่เป็นค่าตัวเลข เช่น

y = 3,500,000 บาท

ดังนั้นจุดแตกต่างที่ง่ายคือ

Classification → ทำนาย “กลุ่ม”

Regression → ทำนาย “ตัวเลข”

2. Unsupervised Learning

Unsupervised Learning คือการเรียนรู้จากข้อมูลที่ **ไม่มี Label** หรือไม่มีคำตอบ y กำกับไว้

ถ้า Supervised คือ

$x \rightarrow y$

Unsupervised จะมีเพียง

x

แล้วให้ Algorithm พยายามค้นหา Pattern หรือโครงสร้างที่ซ่อนอยู่ในข้อมูลด้วยตัวเอง
ตัวอย่างที่สำคัญคือ **Clustering**

Clustering

Clustering คือการนำข้อมูลที่มีลักษณะคล้ายกันมาจัดอยู่ในกลุ่มเดียวกัน โดยเราไม่ได้บอก Machine ล่วงหน้าว่ากลุ่มที่ถูกต้องคืออะไร

เช่น มีข้อมูลลูกค้า 1,000 คน แต่เราไม่ได้บอกว่าเป็นลูกค้ากลุ่ม A, B หรือ C
Machine อาจค้นพบว่า

- กลุ่มหนึ่งซื้อสินค้าราคาสูงบ่อย
- กลุ่มหนึ่งซื้อสินค้าราคาต่ำแต่ซื้อบ่อย
- อีกกลุ่มแทบไม่ซื้อสินค้า

ดังนั้น Machine สามารถแบ่งกลุ่มจาก **Similarity / Pattern** ของข้อมูลได้

Data Analytics

นอกจาก Machine Learning แล้ว ยังมีแนวคิดของ **Data Analytics** ซึ่งสามารถแบ่งตามคำถามที่เราต้องการตอบได้ เช่น

1. Descriptive Analytics

ถามว่า

What happened?

คือการวิเคราะห์ว่าในอดีตหรือปัจจุบันเกิดอะไรขึ้น

เช่น

เดือนนี้ยอดขายลดลง 20%

เป็นการอธิบายสิ่งที่เกิดขึ้นจากข้อมูล

2. Predictive Analytics

ถามว่า

What will likely happen?

คือการใช้ข้อมูลในอดีตและ Model เพื่อคาดการณ์สิ่งที่อาจเกิดขึ้นในอนาคต

เช่น

จากข้อมูลยอดขายที่ผ่านมา Model คาดการณ์ว่าเดือนหน้าอาจมียอดขายประมาณ 1 ล้านบาท

Predictive Analytics สามารถใช้ Machine Learning เป็นหนึ่งในเครื่องมือได้

3. Prescriptive Analytics

ถามว่า

What should we do?

คือการนำข้อมูลและผลการวิเคราะห์มาช่วยตัดสินใจว่า **ควรทำอะไร**

เช่น

หากต้องการเพิ่มยอดขาย ควรเพิ่มสินค้าใด หรือควรทำ Promotion กับลูกค้ากลุ่มใด

ดังนั้นสามคำนี้สามารถจำเป็นลำดับได้ว่า

Descriptive → What happened?
Predictive → What will happen?
Prescriptive → What should we do?

CRISP-DM

อีก Framework ที่มีแนวคิดคล้ายกับ Data Science Process คือ **CRISP-DM (Cross-Industry Standard Process for Data Mining)** ซึ่งเป็นกระบวนการทำงานด้าน Data Mining และ Data Science ที่แบ่งออกเป็น 6 ขั้นตอนหลัก

1. Business Understanding

เข้าใจปัญหาทางธุรกิจหรือปัญหาที่เราต้องการแก้
ถามว่า
ทำไปเพื่ออะไร?
เราต้องการผลลัพธ์อะไร?
ผลลัพธ์นั้นมีประโยชน์ต่อ Business อย่างไร?

2. Data Understanding

ทำความเข้าใจข้อมูลที่เรามี เช่น

- มีข้อมูลอะไรบ้าง
- ข้อมูลมีจำนวนเท่าไร
- ข้อมูลมีประเภทอะไร
- มีข้อมูลผิดพลาดหรือไม่
- มี Pattern อะไรที่น่าสนใจ

ในขั้นตอนนี้ยังเป็นการสำรวจข้อมูลเพื่อดูว่าข้อมูลสามารถนำไปใช้แก้ปัญหาได้หรือไม่

3. Data Preparation

เตรียมข้อมูลให้พร้อมสำหรับการสร้าง Model เช่น

- Clean Data
- Transform Data
- Combine Data
- จัดการ Missing Data
- เลือก Feature ที่เหมาะสม
- เตรียม Label ในกรณีที่ เป็น Supervised Learning

ขั้นตอนนี้มักใช้เวลาค่อนข้างมาก เพราะ **คุณภาพของข้อมูลมีผลโดยตรงต่อคุณภาพของ Model**

4. Modeling

เลือก Algorithm และสร้าง Model จากข้อมูลที่เตรียมไว้
เช่น

- Classification Model
- Regression Model

- Clustering Model
- จากนั้นจึงทำการ Train Model

5. Evaluation

หลังจาก Train แล้วไม่ได้หมายความว่า Model จะดีทันที ต้องมีการประเมินผลก่อน

เราต้องถามว่า

Model ทำนายได้ดีแค่ไหน?

Model มีข้อผิดพลาดตรงไหน?

Model สามารถนำไปใช้กับข้อมูลใหม่ได้หรือไม่?

การประเมินจึงไม่ได้ดูเพียงว่า Model จำข้อมูล Training ได้ดีแค่ไหน แต่ต้องดูว่า Model สามารถ **Generalize** ไปยังข้อมูลที่ไม่เคยเห็นได้ดีหรือไม่

6. Deployment

เมื่อ Model ผ่านการประเมินแล้วจึงนำไปใช้งานจริง เช่น

Model → Application / Website / Database / Production System

จากนั้นเมื่อมีข้อมูลใหม่เข้ามา Model จะนำสิ่งที่เรียนรู้มาใช้ในการ Prediction หรือ Classification

และในระบบจริงยังต้องมีการติดตาม Model ต่อไป เพราะข้อมูลในโลกจริงสามารถเปลี่ยนแปลงได้ ทำให้ Model ที่เคยทำงานได้ดีอาจทำงานได้แยกลงในอนาคต

ปัญหาที่เกิดขึ้นในการ Train Machine Learning

1. Overfitting

Overfitting คือกรณีที่ Model เรียนรู้หรือจดจำ Training Data ได้ดีเกินไปจนเหมือนกับการ “จำข้อสอบ” มากกว่าการเข้าใจ Pattern

ตัวอย่างเช่น

Training Accuracy = 99%

แต่เมื่อเจอข้อมูลใหม่

Test Accuracy = 60%

แสดงว่า Model ทำงานได้ดีมากกับข้อมูลที่เคยเห็น แต่ไม่สามารถ Generalize ไปยังข้อมูลใหม่ได้ดี พุดง่าย ๆ คือ

จำของเก่าเก่ง แต่เจอของใหม่แล้วทำไม่ได้

2. Underfitting

Underfitting เป็นกรณีตรงกันข้าม คือ Model เรียนรู้จากข้อมูลได้ไม่ดีพอ จนไม่สามารถจับ Pattern ที่สำคัญของข้อมูลได้

ตัวอย่างเช่น

Training Accuracy = 60%

Test Accuracy = 58%

ทั้งข้อมูลเก่าและข้อมูลใหม่ก็ทำได้ไม่ดี

พูดง่าย ๆ คือ
ยังเรียนรู้ไม่พอ

3. Learning Feasibility

Learning Feasibility คือการพิจารณาว่า

ปัญหานี้มีความเป็นไปได้หรือไม่ที่ Machine Learning จะสามารถเรียนรู้จากข้อมูลที่เราได้
ไม่ว่าทุกปัญหาจะสามารถ Train ได้ดีเพียงแค่เพิ่ม Algorithm เข้าไป

เราต้องพิจารณาว่า

- มีข้อมูลเพียงพอหรือไม่
- ข้อมูลมีคุณภาพหรือไม่
- มี Pattern ที่สามารถเรียนรู้ได้หรือไม่
- Label ถูกต้องหรือไม่
- ปัญหามีความซับซ้อนมากเกินไปหรือไม่

ถ้าข้อมูลไม่มีความสัมพันธ์กับผลลัพธ์ ต่อให้ Train Model มากเพียงใดก็อาจไม่สามารถสร้าง Model ที่ดีได้

Interpolation และ Extrapolation

4. Interpolation

Interpolation คือการประมาณค่าภายในขอบเขตของข้อมูลที่ Model เคยเรียนรู้

ตัวอย่างเช่น เรามีข้อมูล

- อายุ 20 ปี → รายได้ 15,000 บาท
- อายุ 30 ปี → รายได้ 25,000 บาท
- อายุ 40 ปี → รายได้ 35,000 บาท

ถ้าเราต้องการทำนายรายได้ของคนอายุ 30 ปี ซึ่งอยู่ภายในช่วงข้อมูลที่มีอยู่ ก็เป็นแนวคิดของ Interpolation

พูดง่าย ๆ คือ

ทำนาย “ข้างใน” ช่วงข้อมูลที่เรามี

5. Extrapolation

Extrapolation คือการทำนายค่าที่อยู่นอกขอบเขตของข้อมูลที่ Model เคยเรียนรู้

จากตัวอย่างเดิม ถ้าเรามีข้อมูลอายุ 20–40 ปี แต่ต้องการใช้ Model ไปทำนายคนอายุ 80 ปี นั่นคือการทำนายนอกช่วงข้อมูลที่ Model เคยเห็น

จึงมีความเสี่ยงสูงกว่า เพราะเราไม่สามารถมั่นใจได้ว่า Pattern ที่เกิดขึ้นในช่วง 20–40 ปีจะยังคงเป็น Pattern เดิมเมื่ออายุเพิ่มขึ้นไปถึง 80 ปี

จำง่าย ๆ ว่า

Interpolation = อยู่ในข้อมูล

Extrapolation = ออกนอกข้อมูล

สรุปภาพรวม

ถ้ามองทั้งหมดตั้งแต่ต้นจนจบ เราสามารถมองกระบวนการได้ว่า

Problem

↓

Data

↓

Data Processing

↓

Analysis

↓

Machine Learning

↓

Training

↓

Evaluation

↓

Deployment

โดย Machine Learning ไม่ได้หมายถึงการนำข้อมูลเข้าไป Train เพียงอย่างเดียว แต่เป็นส่วนหนึ่งของกระบวนการที่ใหญ่กว่า ซึ่งเกี่ยวข้องกับ Data Science, Data Processing, Statistics และ Mathematics สิ่งสำคัญที่สุดคือ **ข้อมูล (Data)** เพราะ Machine Learning จะเรียนรู้จากข้อมูลที่เรานำมาให้ หากข้อมูลไม่เพียงพอ มี Bias มี Noise หรือ Label ผิด Model ก็อาจเรียนรู้ Pattern ที่ผิดไปด้วย

ดังนั้นแนวคิดสำคัญที่ควรจำจากบทเรียนนี้คือ

- **Teachable Machine** เป็นตัวอย่างเครื่องมือที่ช่วยให้เราเห็นแนวคิดการสอน Machine จาก Image, Audio และ Pose
- **x** คือ Input / Sample และ **y** คือ Target / Label ในกรณีที่มีคำตอบกำกับ
- **Supervised Learning** มี Label และตัวอย่างสำคัญคือ Classification และ Regression
- **Classification** → ทำนายกลุ่ม
- **Regression** → ทำนายค่าตัวเลข
- **Unsupervised Learning** → ไม่มี Label และให้ Machine ค้นหา Pattern เอง
- **Clustering** → จัดกลุ่มข้อมูลที่มีลักษณะคล้ายกัน
- **Descriptive** → What happened?
- **Predictive** → What will likely happen?
- **Prescriptive** → What should we do?
- **Overfitting** → จำ Training Data ดีเกินไป แต่ข้อมูลใหม่ไม่ดี
- **Underfitting** → เรียนรู้ Pattern ได้ไม่เพียงพอ
- **Interpolation** → ทำนายภายในขอบเขตข้อมูล
- **Extrapolation** → ทำนายนอกขอบเขตข้อมูล
- **CRISP-DM** → Business Understanding → Data Understanding → Data Preparation → Modeling → Evaluation → Deployment

ดังนั้นถ้าจะจำ Machine Learning แบบเป็นความหมาย ไม่ควรจำเพียงชื่อ Algorithm แต่ควรเข้าใจว่า **เรามีปัญหา → เราต้องการข้อมูล → เราเตรียมข้อมูล → เราให้ Machine เรียนรู้ Pattern → เราประเมินว่าเรียนรู้ได้ดีหรือไม่ → แล้วจึงนำ Model ไปใช้กับข้อมูลใหม่**

ซึ่งหัวใจสำคัญของ Machine Learning คือการทำให้ Model สามารถ **Generalize** จากข้อมูลที่เคยเรียนรู้ไปใช้กับข้อมูลใหม่ที่ไม่เคยเห็นมาก่อนได้อย่างเหมาะสม